

# SmartSemaphores - Sistema Multi-agente para a coordenação de semáforos em cruzamentos

Agentes e Inteligência Artificial Distribuída - 2º Projeto  
Grupo 16

Faculdade de Engenharia da Universidade do Porto  
16/12/2018

Membros do grupo 16:

Nádia de Sousa Varela de Carvalho - up201208223 - [ei12047@fe.up.pt](mailto:ei12047@fe.up.pt)

Rúben José da Silva Torres - up201405612 - [up201405612@fe-up.pt](mailto:up201405612@fe-up.pt)

Tiago Lascasas dos Santos - up201503616 - [up201503616@fe.up.pt](mailto:up201503616@fe.up.pt)



# Descrição do problema

- Pretendeu-se realizar um estudo cuidadoso da forma como as várias variáveis da simulação da rede viária influenciam a performance do sistema, procedendo-se à execução de várias simulações usando diversos valores para as variáveis.
- Como tal, pretende-se gerar um modelo que, dado os vários parâmetros que influenciam o sistema, possa prever quanto tempo é que um semáforo passará, em média, no estado verde.
- Numa fase posterior, tentar-se-á descobrir se é possível gerar um modelo que preveja, para cada trajeto possível, quanto tempo é que um veículo irá demorar a percorrê-lo.

# Estatísticas sobre os dados recolhidos (1/3)

Dataset com 61321 exemplos (5110 simulações com 12 exemplos por simulação)

Label ✓ Avg time	Integer	0	Min 1	Max 49	Average 13.978
✓ Semaphore	Integer	0	Min 1	Max 17	Average 9.500
✓ Simulation Type	Polynomial	0	Least CONSENSU [...] S (2017...	Most SMART_AGENTS (2064...	Values SMART_AGENTS (20640), TIMED_AGENTS (20508), ...[1 more]
✓ Emergency Prob.	Real	0	Min 0.005	Max 0.500	Average 0.255
✓ Pedestrian Prob.	Real	0	Min 0.100	Max 1.000	Average 0.552
✓ Exit Rate	Integer	0	Min 1	Max 4	Average 2.486



Semaphore  $\in \{ 1, 3, 4, 6, 8, 10, 11, 12, 13, 14, 15, 17 \}$

Exit Rate  $\in \{ 1, 2, 3, 4 \}$

Simulation Type  $\in \{ \text{TIMED\_AGENTS}, \text{CONSENSUAL\_AGENTS}, \text{SMART\_AGENTS} \}$   
(convertidos para 0, 1 e 2 durante os processos)

A escolha dos valores para Simulation Type, Emergency Prob, Pedestrian Prob e Exit Rate foram escolhidos aleatoriamente no início de cada simulação, tendo sido usada uma distribuição uniforme aleatória para selecionar cada valor.

# Estatísticas sobre os dados recolhidos (2/3)




Distribuição de avg time, numa escala absoluta (esquerda) e logarítmica (direita)


- Avg time é o tempo que um semáforo passou no estado verde durante a simulação (unidade arbitrária). Este valor tem o domínio teórico de  $[1, 120]$ , mas neste dataset nunca é maior que 49.
- É possível observar 3 “picos” de frequência, dois deles centrados no 2 e no 8, enquanto que o terceiro, na zona dos 29-30, encontra-se muito isolado.

# Estatísticas sobre os dados recolhidos (3/3)

■ Pedestrian Prob.



■ Emergency Prob.



- As duas variáveis reais, Emergency Prob e Pedestrian Prob, apresentam uma distribuição a aproximar-se da uniforme, o que vai de encontro à metodologia usada para as gerar em cada simulação. Seria de esperar que, quanto maior fosse o dataset, maior seria a aproximação destas distribuições à distribuição uniforme.

# Análise dos dados com RapidMiner (1/4)

- Aplicou-se o dataset a três modelos distintos: regressão linear, regressão polinomial e k-Nearest Neighbours (k-NN).
- Todos os modelos foram testados, tendo-se medido três indicadores de performance: root mean squared error (RMSE), root relative squared error (RRSE) e a correlação,  $\Theta$ .
- Em todos os modelos realizou-se uma divisão de 70/30 do dataset em treino e teste.

k- Nearest Neighbours	
Root mean squared error (RMSE)	337.107 +/- 0.000
Root relative squared error (RRSE)	0.238
Correlação $\Theta$	0.971

Regressão Linear	
Root mean squared error (RMSE)	3.512 +/- 0.000
Root relative squared error (RRSE)	0.306
Correlação $\Theta$	0.952

#### Equação da regressão linear:

$$T = 13.608 * \text{Simulation Type} + 0.050 * \text{Semaphore} - 5.438 * \text{Emergency Prob.} \\ + 0.766 * \text{Pedestrian Prob.} + 0.265 * \text{Exit Rate}$$

Regressão Polinomial	
Root mean squared error (RMSE)	7.565 +/- 0.000
Root relative squared error (RRSE)	0.659
Correlação $\Theta$	0.808

#### Equação da regressão polinomial:

$$T = -44.051 * \text{Simulation Type} - 0.240 * \text{Semaphore}^2 + 66.840 * \text{Emergency Prob.}^4 - \\ 2.498 * \text{Pedestrian Prob.}^2 + 7.974 * \text{Exit Rate} + 81.772$$

# Análise dos dados com RapidMiner (3/4)

Das 3 regressões utilizadas para a análise, todas elas podem ser consideradas úteis pois têm um menor erro quadrático do que a previsão trivial.

Tendo em conta que o RMSE é o cálculo da média quadrática da diferença entre os valores previstos e reais e que o RRSE é o cálculo do erro quadrático relativo a um modelo trivial que previu a média para cada ponto de dados, podemos observar os seguintes resultados:

- Apesar da regressão **k-NN** apresentar menor RRSE e a maior correlação, este apresenta ao mesmo tempo maior RMSE. O que significa que apesar das suas previsões serem muito melhores em relação a um modelo trivial são por vezes extremamente irrealistas.



# Análise dos dados com RapidMiner (4/4)

- A regressão **Linear** apresenta RMSE mais baixo, e bons valores para RRSE e correlação (comparativamente à regressão k-NN).
- Na regressão **Polinomial** foram obtidos valores sólidos e úteis, no entanto apresenta os piores valores dentre as 3 de correlação e RRSE, sendo a  $\text{Correlação}^2 = R^2 = 0,652$ , o que significa que tem uma menor proporção de variância das variáveis dependentes, ou seja, a regressão apenas explica 65% da variação do tempo que um semáforo passará, em média, no estado verde.

Tendo isto em conta podemos concluir que a regressão que melhor se adapta ao nosso dataset é a **Linear**, pois apresenta RRSE e RMSE relativamente baixos e um  $R^2$  de 0,9 ( $R = \text{correlação}$ ,  $R^2 = 0.952 * 0.952 = 0.906$ )

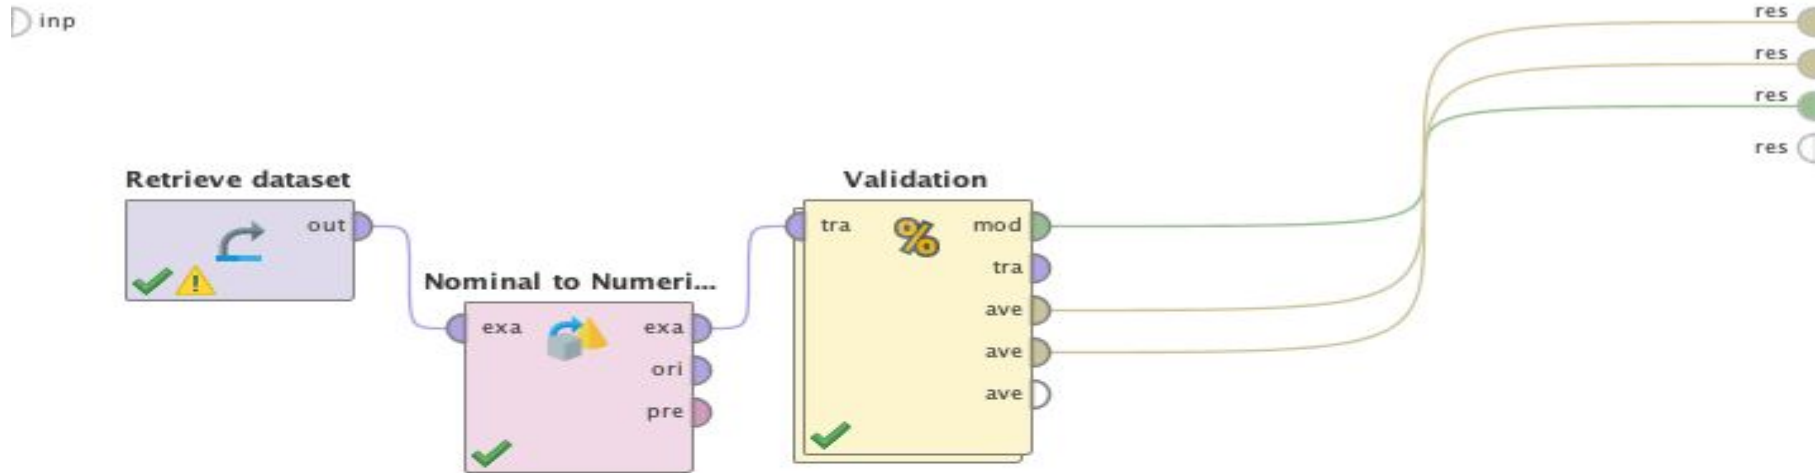
# Conclusões e trabalho futuro

Para tornarmos o trabalho dos nossos agentes no primeiro trabalho mais complicado, temos uma injeção do número veículos na simulação em cada tick extremamente alta e irrealista, o que torna as vias sobrelotadas e leva a tempos em verde ora muito baixos (ex. 2 unidades de tempo), ora relativamente longos (ex. 30 unidades de tempo).

Contudo, é possível, usando um dos modelos, em particular o linear, fazer boas previsões sobre o tempo que cada semáforo passará, em média, no estado verde.

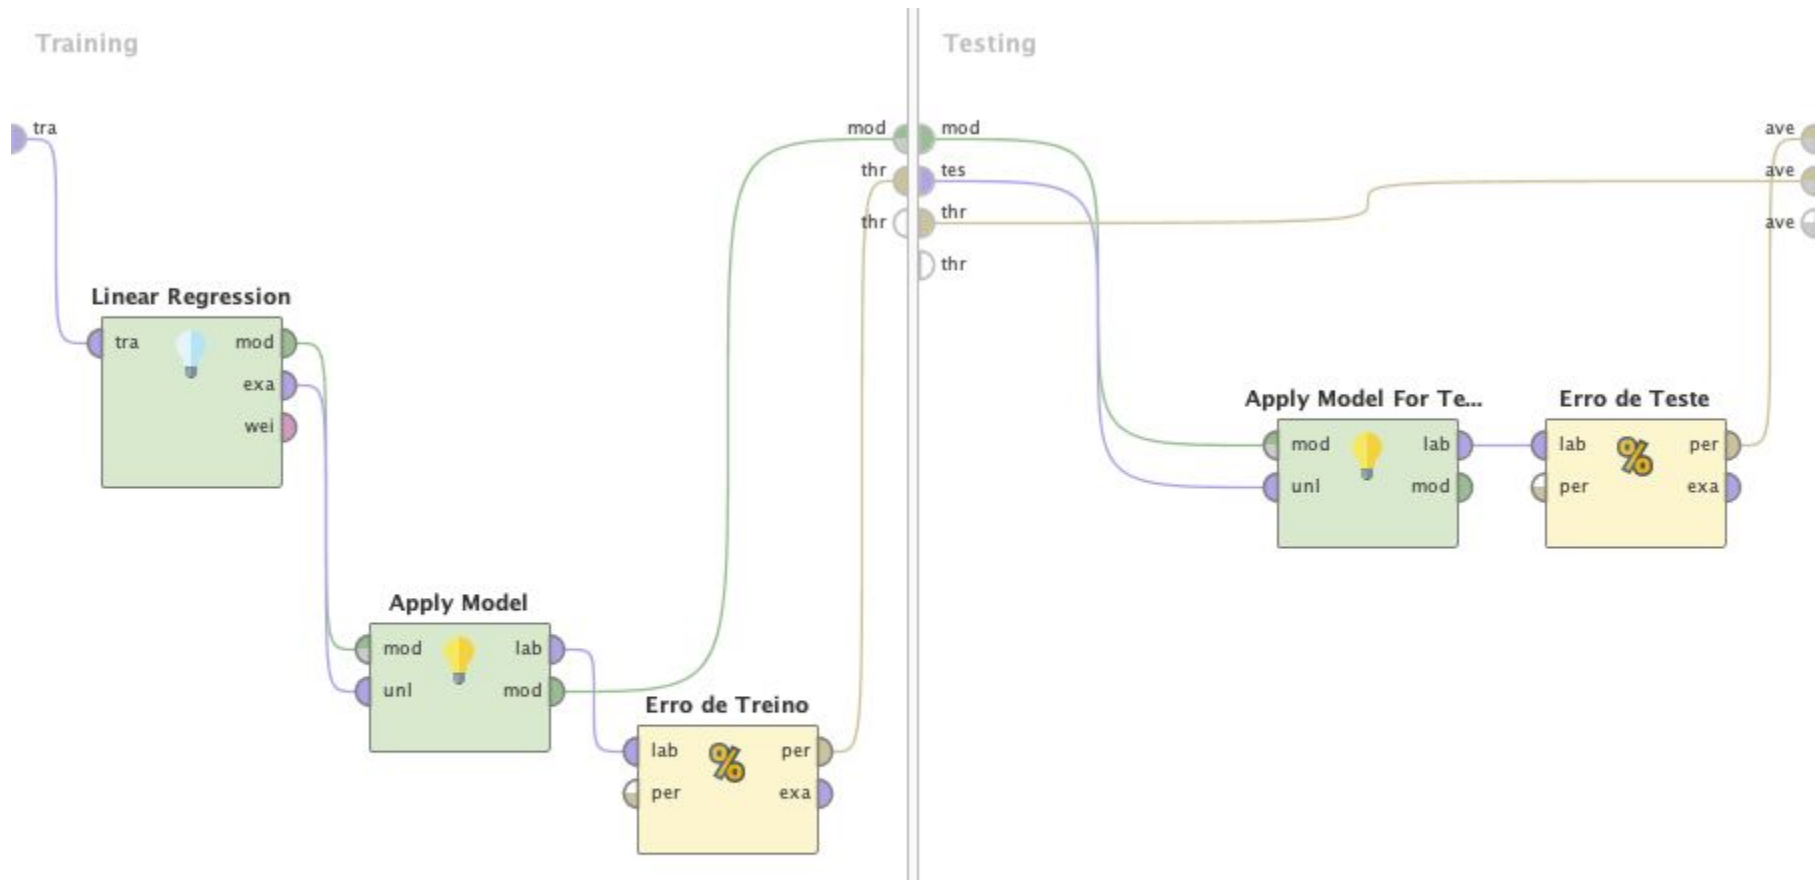
Para trabalho futuro poderia ser feita uma alteração dos parâmetros da simulação para valores considerados realistas, como por exemplo, uma análise e adoção de dados estatísticos de tráfego urbano de uma cidade como Tokyo. Seria também interessante avaliar como os modelos de regressão se adaptariam a tais dados, uma vez que a distribuição dos tempos médios seria, porventura, bastante diferente.

## 2ª parte - Processos RapidMiner



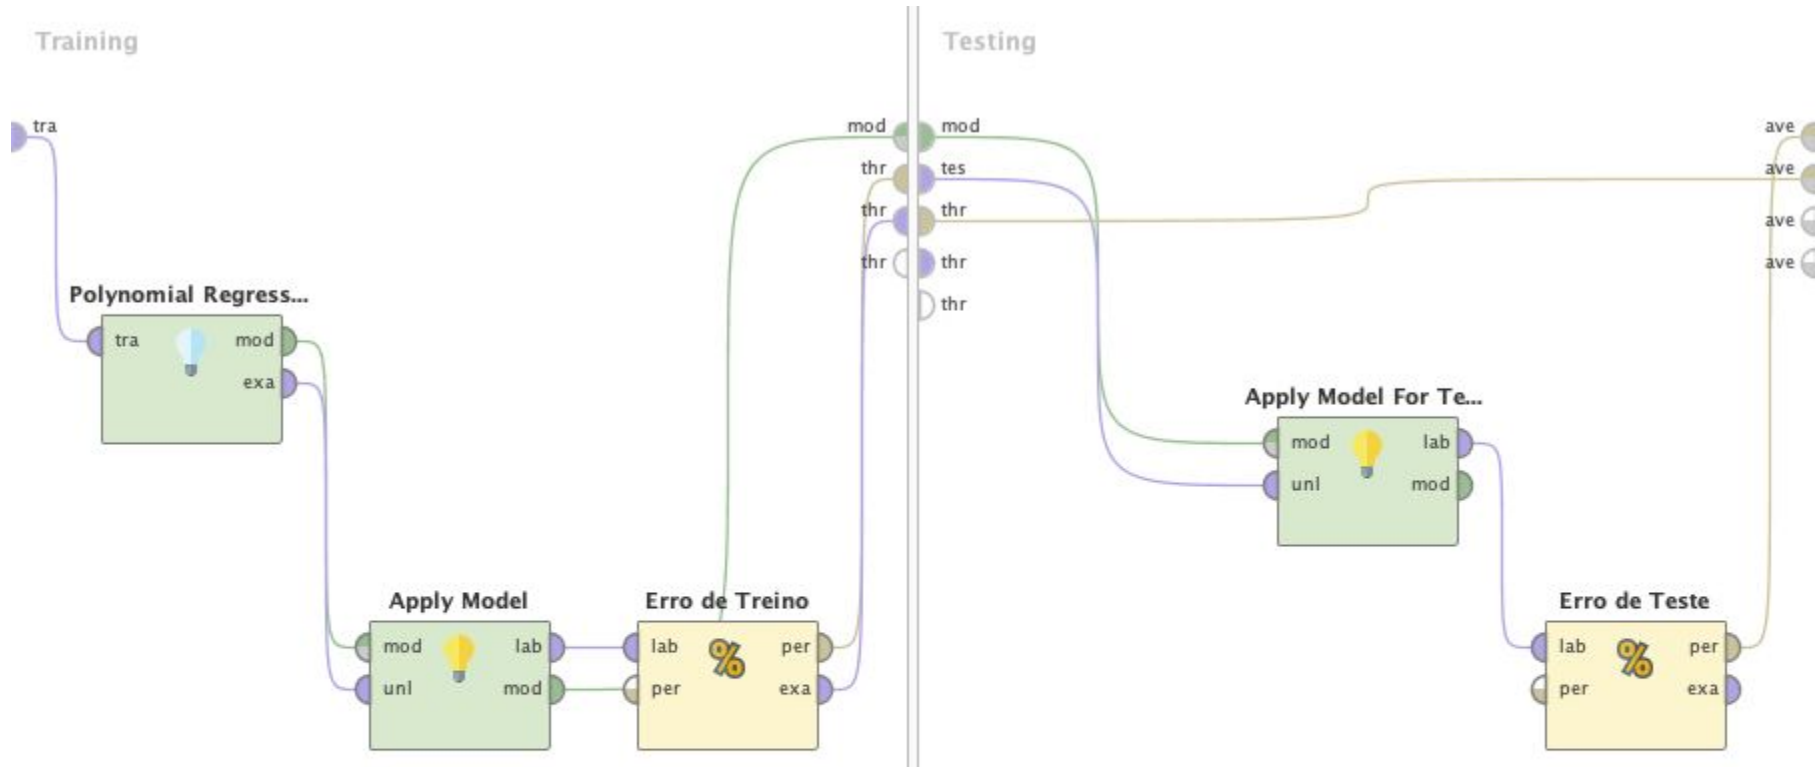
- Todos os Processos realizados no RapidMiner têm esta estrutura exterior, o que nos permite carregar o dataset e, como este tem valores não numéricos (Simulation Type, fazer a sua conversão para valores numéricos e, posteriormente, fazer a validação do modelo, dividindo o dataset em dataset de treino e teste (0.70/0.30).
- O modelo é aplicado dentro da “caixa” de validação e são calculadas as performances para ambos os datasets para todos os tipos de modelo experimentados

# Processos RapidMiner - Linear Regression



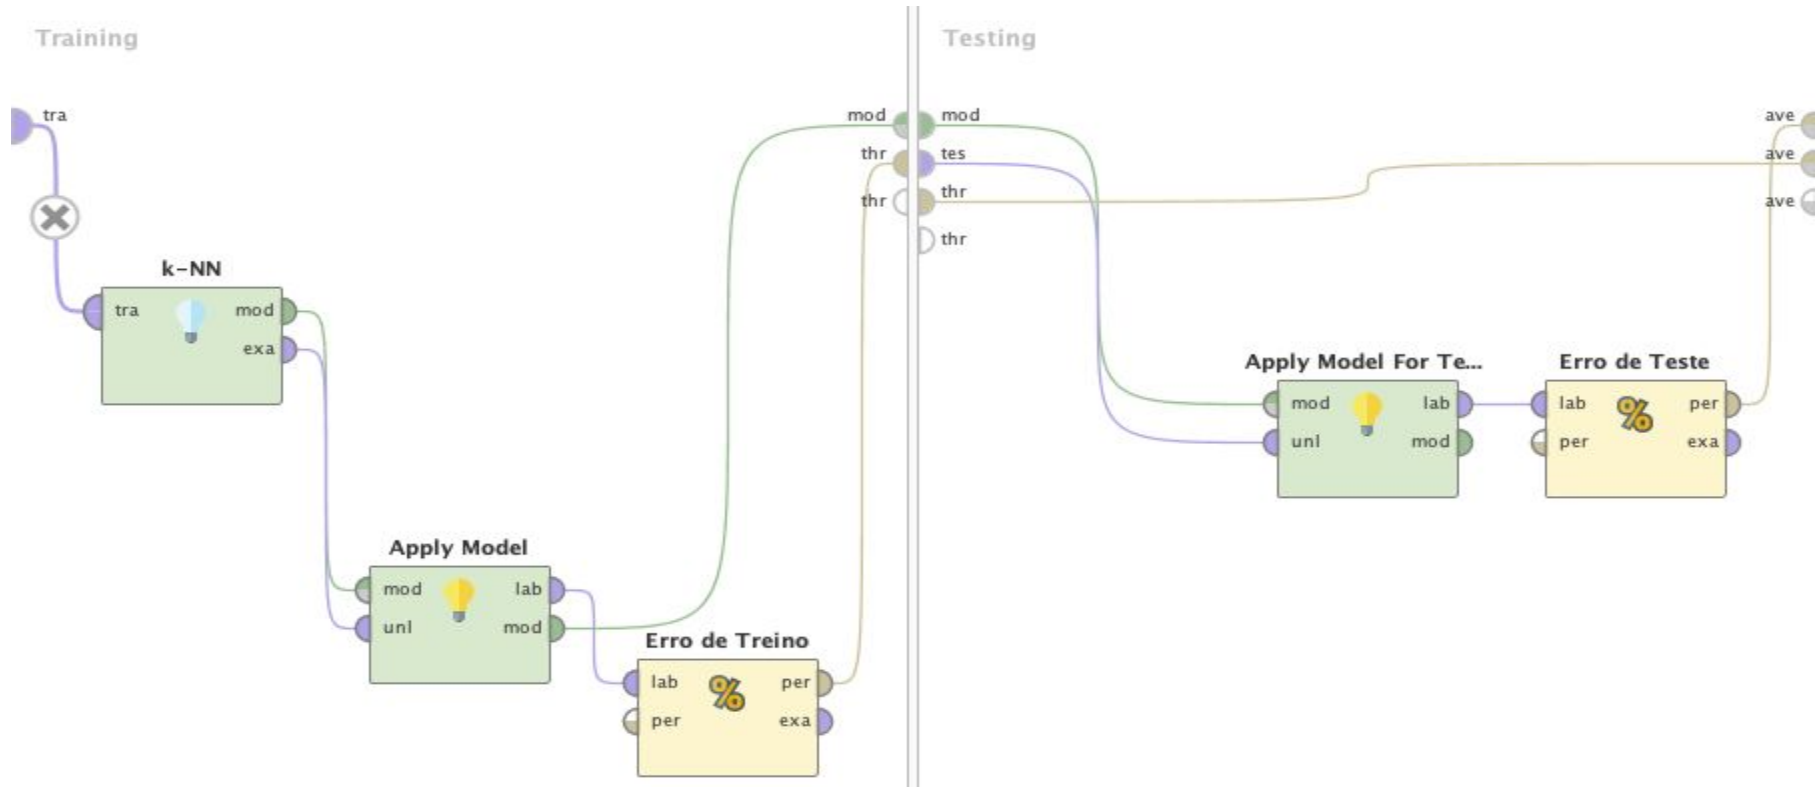
- O modelo de Regressão Linear tenta modelar a relação entre uma variável escalar e uma ou mais variáveis (numéricas) independentes, obtendo uma equação linear para a informação observada.
- Os medidores de performance “Erro de Teste” e “Erro de Treino” fazem, para o modelo, o cálculo de root mean squared error (RMSE), root relative squared error (RRSE) e a correlação,  $\Theta$ .

# Processos RapidMiner - Polynomial Regression



- O modelo de Regressão Polinomial tenta modelar a relação entre uma variável escalar e uma ou mais variáveis (numéricas) independentes, obtendo uma equação não-linear, de grau  $n$ , para a informação observada. É considerado um caso especial de regressão linear múltipla.
- Os medidores de performance “Erro de Teste” e “Erro de Treino” fazem, para o modelo, o cálculo de root mean squared error (RMSE), root relative squared error (RRSE) e a correlação,  $\Theta$ .

# Processos Rapidminer - k-NN



- O modelo de k-NN tenta modelar a relação entre uma variável escalar e uma ou mais variáveis (numéricas) independentes, comparando um exemplo desconhecido com os seus  $k$  vizinhos mais próximos nos exemplos de treino. A proximidade é definida em termos de distância no espaço de  $n$  dimensões, definido pelos  $n$  atributos definidos nos exemplo de treino.
- Os medidores de performance “Erro de Teste” e “Erro de Treino” fazem, para o modelo, o cálculo de root mean squared error (RMSE), root relative squared error (RRSE) e a correlação,  $\Theta$ .

# Resultados de outras experiências interessantes (1/5)

- Como mencionado no início, foi também contemplada a situação em que se pretende prever o tempo médio que um veículo irá demorar a percorrer a rede de estradas para cada par de entradas e saídas. Para tal, gerou-se um novo dataset com 277632 exemplos (7712 simulações com 36 exemplos por simulação). Cada simulação produz o tempo médio que um veículo demorou a percorrer a rede, havendo 36 percursos possíveis.
- Este dataset é em tudo igual ao dos semáforos, exceto que a coluna Avg Time tem um novo significado, e a coluna Semaphore foi substituída por duas colunas, Start e Exit, correspondentes a cada entrada e saída.

## Resultados de outras experiências interessantes (2/5)

Label ✓ <b>Avg Time</b>	Integer	0	Min 591	Max 17427	Average 2349.530
✓ <b>Start</b>	Integer	0	Min 1	Max 17	Average 9.500
✓ <b>Exit</b>	Integer	0	Min 2	Max 18	Average 9.500
✓ <b>Simulation Type</b>	Polynomial	0	Least CONSENSU [...] S (5450...	Most TIMED_AGENTS (54648)	Values TIMED_AGENTS (54648)
✓ <b>Emergency Prob.</b>	Real	0	Min 0.005	Max 0.500	Average 0.253
✓ <b>Pedestrian Prob</b>	Real	0	Min 0.100	Max 1.000	Average 0.555
✓ <b>Exit Rate</b>	Integer	0	Min 1	Max 4	Average 2.498

Resumo do dataset dos veículos



## Resultados de outras experiências interessantes (3/5)

À semelhança da anterior, foram criados dois modelos, uma regressão linear e um k-NN, para averiguar se é possível obter um modelo preditivo a partir destes dados. Os resultados foram os seguintes:

Regressão Linear	
Root mean squared error (RMSE)	1478.461 +/- 0.000
Root relative squared error (RRSE)	1.035
Correlação $\Theta$	0.317

## Resultados de outras experiências interessantes (4/5)

k-Nearest Neighbours	
Root mean squared error (RMSE)	299.976 +/- 0.000
Root relative squared error (RRSE)	0.210
Correlação $\Theta$	0.978

Podemos observar neste caso que dos dois modelos utilizadas para a análise, a linear pode ser considerada inútil porque tem um erro quadrático maior do que a previsão trivial. A k-NN tem valores muito bons de RRSE e correlação, mas o RMSE é bastante mau, visto que significa que existe um erro médio de 300 unidades de tempo em cada previsão.

## Resultados de outras experiências interessantes (5/5)

Isto acontece porque não sabemos nada sobre o tempo que um veículo demora a percorrer um determinado trajeto (um veículo que começa em A e acaba em B nem sempre toma o caminho mais curto, por exemplo).

A razão por essa incerteza quanto ao caminho advém do facto de que na nossa simulação os veículos não são injetados com um objetivo de saírem da simulação num determinado sítio; simplesmente têm uma igual de probabilidade de irem para qualquer um dos caminhos possíveis após o semáforo da sua via passar verde, sendo que cada veículo apenas sabe o seu ponto de saída quando, de facto, calhar numa saída.